Implementación de un Modelo Predictivo de IA para la Optimización de Servicios en el Sector Financiero y de Startups.

Alumna: Esleibi Colina.

Licenciatura en Inteligencia Artificial.

Profesor: Héctor Mendoza.

Institución: IPL Instituto Profesional de Líderes.

Septiembre, 2026

INTRODUCCIÓN

La inteligencia artificial (IA) ha dejado de ser una simple herramienta tecnológica para convertirse en el motor fundamental de la transformación económica y social actual. Desde sectores tradicionales como la salud y la educación hasta las finanzas y la logística, la IA redefine la forma en que interactuamos con el mundo. El presente proyecto práctico tiene como propósito general integrar los conceptos teóricos de la innovación y el emprendimiento en IA mediante la construcción de una solución basada en datos, aplicando un enfoque estructurado que abarca desde la conceptualización del problema hasta su evaluación técnica y comercial.

Descripción del Problema y los Datos

Definición del Problema

Para este proyecto, abordamos un desafío común en el ecosistema de las startups y las empresas financieras: **la predicción de riesgo o comportamiento de clientes** (por ejemplo, identificar qué usuarios requieren una atención o gestión personalizada basada en sus patrones de interacción). Resolver este problema de manera automatizada optimiza los recursos operativos y genera un valor diferencial en el mercado.

Obtención y Simulación de Datos

Dado que requerimos un conjunto de datos para entrenar nuestro sistema, simularemos una base de datos estructurada en Python que representa las características clave de los usuarios (como antigüedad, nivel de transaccionalidad, uso de servicios y una etiqueta objetivo que indica si el cliente representa o no una oportunidad de éxito/riesgo).

Preparación de Datos

Implementación del Modelo Aplicando Innovación y Emprendimiento

Enfoque de Innovación y Modelo de Negocio

- Tipo de Innovación: Se aplica una innovación incremental enfocada en mejorar de forma continua la eficiencia operativa de un servicio ya existente, optimizando los tiempos de respuesta y la precisión en la toma de decisiones.

- Modelo de Negocio: La solución se proyecta bajo un modelo SaaS (Software as a Service) combinado con un enfoque B2B (Business to Business), permitiendo ofrecer el acceso al software predictivo mediante una suscripción mensual a otras empresas que deseen integrar esta tecnología en sus operaciones.

- Producto Mínimo Viable (MVP): Se desarrolla un prototipo funcional y ligero utilizando librerías de aprendizaje automático en Python para validar la viabilidad técnica antes de escalar la infraestructura a la nube.

Entrenamiento y Evaluación con Métricas

Proceso de Entrenamiento

El algoritmo de aprendizaje automático analiza el 80% de los datos de entrenamiento para descubrir patrones ocultos entre las características de los usuarios y el comportamiento esperado.

Evaluación de Resultados

Para medir el éxito de la solución de manera objetiva, utilizamos métricas cuantitativas estándar:

- **Exactitud (Accuracy):** Porcentaje global de aciertos del modelo en el conjunto de prueba.
- **Reporte de Clasificación:** Detalle de precisión y sensibilidad para evaluar el rendimiento en cada categoría de predicción.

Tras la ejecución del modelo de clasificación basado en Random Forest, se evaluó el rendimiento utilizando el conjunto de prueba (20% de los datos). Los resultados arrojaron una exactitud (Accuracy) global de 1.0, complementada con valores máximos de precisión, sensibilidad (*recall*) y puntaje F1 en ambas categorías. Esto valida técnicamente la solidez del Producto Mínimo Viable (MVP), confirmando que las variables seleccionadas contienen los patrones necesarios para que el algoritmo tome decisiones automatizadas precisas.

Resultados.

```
Exactitud del Modelo (Accuracy): 1.0

Reporte de Clasificación:
              precision    recall  f1-score   support

           0       1.00      1.00      1.00       146
           1       1.00      1.00      1.00        54

    accuracy                           1.00       200
   macro avg       1.00      1.00      1.00       200
weighted avg       1.00      1.00      1.00       200
```

Interpretación de los Resultados.

1. **Precisión, Recall y F1-Score en 1.00**:
    - **Clase 0 (Sin riesgo):** El modelo identificó correctamente al 100% de los usuarios que no presentaban el indicador objetivo.
    - **Clase 1 (Con riesgo):** El modelo también acertó en el 100% de los casos positivos. No hubo "falsos positivos" ni "falsos negativos" en tu conjunto de prueba.
2. **¿Por qué se obtiene un 1.0 perfecto?**
    - Como nuestro conjunto de datos fue simulado en Python mediante una regla matemática directa *(df['Objetivo'] = np.where((df['Interacciones_Plataforma'] > 50) & (df['Gasto_Promedio'] > 200), 1, 0))*, el patrón de comportamiento es lógico y exacto.
    - En un **entorno real**, los datos de los usuarios suelen ser más complejos o tener excepciones, por lo que una precisión del 100%

es infrecuente (suele rondar entre el 85% y el 95%). Sin embargo, para un **Producto Mínimo Viable (MVP)** y una simulación académica, este resultado demuestra que la tubería de datos (*data pipeline*), la normalización y el modelo están perfectamente implementados y sincronizados.

Conclusiones, Ética y Propuestas de Mejora

- El desarrollo demuestra que la combinación de un algoritmo eficiente con un modelo de negocio claro (como SaaS) permite crear soluciones escalables con un alto impacto comercial.
- **Escalabilidad y Crecimiento:** Para futuras fases, la solución puede alojarse en plataformas en nube (como AWS o Google Cloud) para soportar un mayor volumen de usuarios sin incrementar los costos físicos de infraestructura.
- **Consideraciones Éticas y Legales:** Es vital garantizar la transparencia y explicabilidad de los algoritmos para evitar sesgos que puedan afectar a los usuarios, cumpliendo estrictamente con normativas de privacidad de datos.

REFERENCIAS

- Material de Estudio Institucional. (2026). *Fundamentos de la Innovación y Emprendimiento en Inteligencia Artificial: Modelos de negocio, estrategias de crecimiento y aspectos éticos*. Módulo académico de referencia.
- **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É.** (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research.*
- **Gron, A.** (2022). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (3.ª ed.). O'Reilly Media.
- **Bedoya Sánchez, E. O.** (2026). Adopción de inteligencia artificial en PYMES de economías emergentes. *Revista Venezolana de Gerencia*, 31(107), 1–15.
- **Acosta, O. B.** (2026). Uso de inteligencia artificial (IA) en mipymes de América Latina. *European Public & Social Innovation Review*, 11, 1–18. https://doi.org/10.31637/epsir-2026-2334